

Projektisuunnitelma: Rintasyövän maligniteetin ennustaminen koneoppimisella

1. Projektin tarkoitus

Projektini tavoitteena on tutkia, voidaanko rintakasvaimen maligniteettia ennustaa solutumien morfologisten ominaisuuksien perusteella. Ensin pyrin tunnistamaan ennustamisen kannalta tärkeimmät muuttujat ja rakentamaan niiden avulla logistisen regressiomallin. Tämän jälkeen rakennan Random Forest -mallin samoilla muuttujilla ja vertailen menetelmien ennustekykyä.

Tutkimuskysymykset:

- Mitkä solutumien ominaisuudet ovat yhteydessä maligniteettiin?
- Voidaanko hyvän- ja pahanlaatuiset kasvaimet erottaa pienellä muuttujajoukolla?
- Parantaako Random Forest ennustekykyä logistiseen regressioon verrattuna?

2. Aineisto

Käytän Breast Cancer Wisconsin (Diagnostic) -aineistoa, joka on saatavilla UCI Machine Learning Repositorysta ja scikit-learn-kirjastosta.

Aineisto sisältää 569 näytettä ja 30 numeerista muuttujaa, jotka kuvaavat esimerkiksi solutumien kokoa, muotoa ja tekstuuria.

Ennustettava muuttuja on diagnoosi:

- 0 = hyvänlaatuinen (benign)
- 1 = pahanlaatuinen (malignant)

3. Analyysin toteutus

1. Aineiston alustava analyysi
Tutkin aineiston rakennetta, luokkajakaumaa, muuttujien jakaumia, puuttuvia arvoja ja korrelaatioita.
2. Logistinen regressio
Jaan aineiston opetus- ja testijoukkoihin suhteessa 80/20. Rakennan ensin logistisen regressiomallin kaikilla 30 muuttujalla.

Valitsen tärkeimmät muuttujat opetusdatassa esimerkiksi L1-regularisoinnin avulla ja rakennan supistetun regressiomallin.

3. Random Forest

Rakennan Random Forest -luokittelumallin käyttäen samoja valittuja muuttujia kuin supistetussa logistisessa regressiomallissa.

Optimoin tarvittavat hyperparametrit opetusdatassa ristivalidoinnin avulla.

4. Mallien vertailu

Vertaan kolmea malliversiota:

- Logistinen regressio, 30 muuttujaa.
- Logistinen regressio, valitut muuttujat.
- Random Forest, valitut muuttujat.

5. Päättävöitteena on verrata kahta jälkimmäistä mallia. Käytän kaikille malleille samaa testiaineistoa.

4. Mallien arviointi

Ensisijaiset arviointimittarit ovat sensitiivisyys ja spesifisyys. Lisäksi käytän ROC-AUC-arvoa luokkien erottelukyvyn arvioimiseen.

Valitsen päätöskynnykset ja optimoin mallit opetusdatassa ristivalidoinnin avulla. Muuttujavalinta ja standardointi tehdään ilman testidatan käyttöä.

Lopullinen mallien arviointi tehdään erillisellä testiaineistolla.

5. Projektin laajuus ja aikataulu

Vaihe	Sisältö	Palautus
1	Aineiston tutkiminen, tutkimuskysymys ja logistisen regression valinta	18.9.2026
2	Mallien toteutus, muuttujavalinta, Random Forest ja vertailu	7.10.2026

Ensimmäisessä vaiheessa keskityn aineiston alustavaan analyysiin ja valitun menetelmän perusteluun. Varsinainen mallien kouluttaminen toteutetaan toisessa vaiheessa.

Jos aikaa jää, laajennan analyysiä tutkimalla muuttujavalinnan vakautta, muuttujien tärkeyttä ja päätöskynnysten vaikutusta ennustetuloksiin.

