

Rintasyövän maligniteetin ennustaminen koneoppimismalleilla

1. Johdanto

Projektini tavoitteena on tutkia, voidaanko rintakasvaimen maligniteettia ennustaa solutumien morfologisten ominaisuuksien perusteella. Pyrin tunnistamaan ennustamisen kannalta tärkeimmät muuttujat ja rakentamaan niiden avulla luokittelumallin.

Ensimmäisessä vaiheessa keskityn aineiston tutkimiseen ja logistisen regression suunnitteluun. Toisessa vaiheessa vertaan logistisen regression ja Random Forest -mallin ennustekykyä.

2. Ongelman määrittely

Kyseessä on ohjattu kaksiluokkainen luokitteluongelma (*binary classification*).

Käytän UCI Machine Learning Repositorysta saatavaa *Breast Cancer Wisconsin (Diagnostic)* -aineistoa. Aineisto sisältää 569 näytettä ja 30 numeerista muuttujaa, jotka kuvaavat solutumien kokoa, muotoa ja tekstuuria.

Syötemuuttujat (X) ovat 30 morfologista ominaisuutta. Ennustettava muuttuja (y) on kasvaimen diagnoosi:

- 0 = hyvänlaatuinen
- 1 = pahanlaatuinen

Tavoitteena on ennustaa maligniteettia mahdollisimman luotettavasti ja selvittää, mitkä ominaisuudet sisältävät eniten ennustamisen kannalta hyödyllistä tietoa.

3. Menetelmät

3.1 Aineiston esikäsittely

Tutkin aluksi muuttujien jakaumia, puuttuvia arvoja ja keskinäisiä korrelaatioita.

Jaan aineiston ositetusti opetus- ja testijoukkoihin suhteessa 75/25. Käytän opetusdataa mallin kehittämiseen ja viisinkertaista ristivalidointia mallin arviointiin sekä optimointiin.

Standardoin muuttujat käyttäen ainoastaan opetusdatasta laskettuja parametreja. Ristivalidoinnissa standardointi sovitetaan erikseen kunkin kierroksen opetusosaan.

3.2 Mallin valinta

Valitsen ensimmäiseksi menetelmäksi logistisen regression, koska ennustettava muuttuja on binäärinen.

Malli arvioi maligniteetin todennäköisyyttä muuttujien lineaarisen yhdistelmän perusteella. Käytän häviöfunktiona logistista häviötä (*logistic loss*).

Rakennan ensin mallin kaikilla 30 muuttujalla. Tämän jälkeen valitsen ennustamisen kannalta tärkeimmät muuttujat opetusdatassa L1-regularisoinnin avulla ja muodostan supistetun mallin.

3.3 Mallin arviointi

Arvioin mallin ennustekykyä ensisijaisesti sensitiivisyyden ja spesifisyyden avulla. Lisäksi käytän ROC-AUC-arvoa.

Valitsen luokittelukynnyksen opetusdatassa ristivalidoinnin avulla. Lopullinen arviointi tehdään erillisellä testiaineistolla, jota ei käytetä mallin kehittämiseen.

4. Tekoälyn käyttö

Hyödynsin ChatGPT:tä aineiston etsimisessä, projektisuunnitelman jäsentelyssä sekä raportin oikeinkirjoituksen tarkistamisessa ja kielellisessä viimeistelyssä. Toteutan analyysikoodin itsenäisesti ja teen tulosten lopulliset tulkinnat itse.

5. Lähteet

Wolberg et al. *Breast Cancer Wisconsin (Diagnostic)*. [UCI Machine Learning Repository](https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+(Diagnostic)).

6. Koodit

Aineiston alustavassa analyysissä käyttämäni Jupyter Notebook on saatavilla julkisessa GitHub-repositoriossa:

<https://github.com/bumerrang2808/Machine-learning-project>