

Rintasyövän maligniteetin ennustaminen koneoppimisella

1. Projektin tarkoitus

Tavoitteena oli tutkia, voidaanko rintakasvaimen maligniteettia ennustaa solutumien morfologisten ominaisuuksien perusteella ja voidaanko muuttujien määrää vähentää ilman selvää suorituskyvyn heikkenemistä.

Tutkimuskysymykset olivat:

- Mitkä solutumien ominaisuudet liittyvät maligniteettiin?
- Riittääkö pienempi muuttujajoukko luokitteluun?
- Parantaako Random Forest tulosta logistiseen regressioon verrattuna?

Vertasin kolmea mallia: logistista regressiota kaikilla muuttujilla, logistista regressiota valituilla muuttujilla ja Random Forestia samoilla valituilla muuttujilla.

2. Aineisto

Käytin Breast Cancer Wisconsin (Diagnostic) -aineistoa, jossa on 569 näytettä ja 30 solutumien kokoa, muotoa ja tekstuuria kuvaavaa numeerista muuttujaa.

Kohdemuuttuja oli diagnoosi: 0 = hyvänlaatuinen ja 1 = pahanlaatuinen.

Aineisto jaettiin ositetusti 75 % opetusdataan ja 25 % testidataan. Opetusdata sisälsi 426 ja testidata 143 näytettä.

Stage 1:n analyysissä useat kokoa kuvaavat muuttujat, kuten radius, perimeter ja area, korreloivat voimakkaasti keskenään. Siksi muuttujia ei poistettu käsin, vaan valinta tehtiin mallinnuksen yhteydessä.

3. Menetelmät

3.1 Logistinen regressio

Ensimmäinen logistinen regressiomalli käytti kaikkia 30 muuttujaa. Muuttujat standardoitiin ja regularisaatioparametri C valittiin viisikertaisella ositetulla ristiinvalidoinnilla ROC-AUC:n perusteella. Paras arvo oli $C = 0,1$, ja ristiinvalidoinnin ROC-AUC oli 0,992.

3.2 Muuttujien valinta

Muuttujat valittiin L1-regularisoidulla logistisella regressiolla käyttäen vain opetusdataa. L1 voi asettaa osan kertoimista nolaksi ja näin pienentää muuttujajoukkoa.

Paras C -arvo oli 1, ja 30 muuttujasta valittiin 15. Suurimmat positiiviset kertoimet olivat muuttujilla **radius error**, **worst area**, **worst texture**, **mean concave points** ja **worst radius**.

3.3 Mallit valituilla muuttujilla

Valituilla 15 muuttujalla rakennettiin uusi logistinen regressio ja Random Forest.

Logistisen regression paras C oli 1 ja ristiinvalidoinnin ROC-AUC 0,989.

Random Forest käytti 200 päätöspuuta. Paras malli käytti rajoittamatonta puun syvyyttä ja lehden vähimmäiskokoa 1. Myös sen ristiinvalidoinnin ROC-AUC oli 0,989.

3.4 Arviointi

Jokaiselle mallille valittiin päätöskynnys opetusdatasta maksimoimalla Youdenin J -arvo:

$$J = \text{sensitiivisyys} + \text{spesifisyys} - 1.$$

Testidataa käytettiin vasta lopulliseen arviointiin. Mallien vertailussa käytettiin sensitiivisyyttä, spesifisyyttä, ROC-AUC:ta ja accuracy-arvoa.

4. Tulokset


Malli	Muutt uji a	Sensitiivi syys	Spesifi syy s	ROC-A UC	Accur ac y
Logistinen regressio, kaikki	30	0,981	1,000	0,998	0,993

Logistinen regressio, valitut	15	0,943	0,989	0,998	0,972
Random Forest, valitut	15	0,925	1,000	0,997	0,972

Kaikki mallit toimivat hyvin. Paras testitulos saatiin logistisella regressiolla, jossa käytettiin kaikkia 30 muuttujaa.

Muuttujamäärän vähentäminen 30:stä 15:een ei käytännössä muuttanut ROC-AUC-arvoa, mutta sensitiivisyys laski hieman.

Random Forest ei parantanut tulosta valittujen muuttujien logistiseen regressioon verrattuna. Molempien 15 muuttujan mallien accuracy oli 0,972.



Kuva 1. Mallien ROC-käyrät testiaineistossa.

5. Pohdinta

Tulosten perusteella rintakasvaimen maligniteettia voidaan ennustaa hyvin tämän aineiston solutumaominaisuuksilla. Kaikkien mallien ROC-AUC oli vähintään 0,997.

L1-valinta puolitti muuttujien määrän ilman selvää muutosta ROC-AUC:ssa. Pienempi logistinen malli oli myös hieman parempi kuin Random Forest sensitiivisyyden ja ROC-AUC:n perusteella. Koska se on lisäksi yksinkertaisempi, valitsisin päävertailussa 15 muuttujan logistisen regression.

Kaikkien 30 muuttujan logistinen regressio sai parhaat testitulokset. Eroja pitää kuitenkin tulkita varovasti, koska testiaineistossa oli vain 143 näytettä. Random Forestin hyperparametrien haku oli myös melko rajattu.

6. Generatiivisen tekoälyn käyttö

Hyödynsin ChatGPT:tä aineiston etsimisessä, projektisuunnitelman jäsentelyssä sekä raportin oikeinkirjoituksen ja kielen tarkistamisessa. Toteutin analyysikoodin itse ja tein tulosten lopulliset tulkinnat itse.

7. Koodit

Analyysikoodi on saatavilla julkisessa GitHub-repositoriossa:

[Machine learning project - GitHub](#)

Lähteet

1. Wolberg, W. H., Street, W. N. & Mangasarian, O. L. *Breast Cancer Wisconsin (Diagnostic)*. UCI Machine Learning Repository.