

Rintasyövän maligniteetin ennustaminen koneoppimisella

1. Projektin tarkoitus

Projektin tavoitteena oli tutkia, voidaanko rintakasvaimen maligniteettia ennustaa solutumien morfologisten ominaisuuksien perusteella. Lisäksi halusin selvittää, voidaanko ennustamiseen tarvittavien muuttujien määrää vähentää ilman suurta muutosta mallin suorituskyvystä.

Tutkimuskysymykset olivat:

- Mitkä solutumien ominaisuudet ovat yhteydessä maligniteettiin?
- Voidaanko hyvän- ja pahanlaatuiset kasvaimet erottaa pienemmällä muuttujajoukolla?
- Parantaako Random Forest ennustekykyä logistiseen regressioon verrattuna?

Vertasin kolmea mallia: logistista regressiota kaikilla muuttujilla, logistista regressiota valituilla muuttujilla sekä Random Forest -mallia samoilla valituilla muuttujilla.

2. Aineisto

Käytin Breast Cancer Wisconsin (Diagnostic) -aineistoa. Aineisto sisältää 569 rintakasvaimen ohutneulanäytettä ja 30 numeerista muuttujaa. Muuttujat kuvaavat solutumien ominaisuuksia, kuten kokoa, muotoa, tekstuuria ja pinnan epäsäännöllisyyttä.

Kohdemuuttuja oli diagnoosi:

- 0 = hyvänlaatuinen
- 1 = pahanlaatuinen

Aineistossa oli 357 hyvänlaatuista ja 212 pahanlaatuista näytettä. Stage 1:ssä aineisto jaettiin ositetusti 75 % opetusdataan ja 25 % testidataan. Opetusdata sisälsi 426 näytettä ja testidata 143 näytettä. Testidatassa oli 90 hyvänlaatuista ja 53 pahanlaatuista tapaus.

Stage 1:n korrelaatioanalyysissä havaittiin, että useat kokoa kuvaavat muuttujat, kuten radius, perimeter ja area, korreloivat hyvin voimakkaasti keskenään. Myös useat samaa ominaisuutta kuvaavat mean- ja worst-muuttujat korreloivat keskenään. Tämän vuoksi muuttujien valinta tehtiin mallinnuksen yhteydessä eikä muuttujia poistettu käsin.

3. Menetelmät

3.1 Logistinen regressio kaikilla muuttujilla

Ensimmäinen malli oli logistinen regressio, jossa käytettiin kaikkia 30 muuttujaa. Koska muuttujien mittakaavat eroavat paljon toisistaan, muuttujat standardoitiin ennen mallin sovittamista.

Regularisaation voimakkuutta kuvaava parametri C valittiin viisikertaisella ositetulla ristiinvalidoinnilla. Vertailtavat arvot olivat 0,01, 0,1, 1 ja 10. Mallin valintamittarina käytettiin ROC-AUC-arvoa. Paras arvo oli $C = 0,1$, ja ristiinvalidoinnin ROC-AUC oli 0,992.

3.2 Muuttujien valinta

Muuttujien valintaan käytettiin L1-regularisoitua logistista regressiota. L1-regularisaatio voi asettaa vähemmän hyödyllisten muuttujien kertoimet nolaksi, jolloin jäljelle jää pienempi muuttujajoukko.

Muuttujavalinta ja parametrien valinta tehtiin vain opetusdatalla. Testidataa ei käytetty tässä vaiheessa. L1-mallin parhaaksi parametriksi saatiin $C = 1$, ja 30 muuttujasta valittiin 15.

Suurimmat positiiviset kertoimet olivat muuttujilla **radius error**, **worst area**, **worst texture**, **mean concave points** ja **worst radius**. Tämä viittaa siihen, että erityisesti kasvaimen kokoon, teksturiin ja muodon epäsäännöllisyyteen liittyvät ominaisuudet olivat hyödyllisiä maligniteetin ennustamisessa. Koska osa muuttujista korreloi voimakkaasti keskenään, yksittäisten kertoimien merkitystä ei kuitenkaan pidä tulkita täysin itsenäisesti.

3.3 Logistinen regressio valituilla muuttujilla

Toinen logistinen regressiomalli rakennettiin L1-menetelmällä valituilla 15 muuttujalla. Muuttujat standardoitiin samalla tavalla kuin ensimmäisessä mallissa.

Regularisaatioparametri valittiin jälleen viisikertaisella ristiinvalidoinnilla. Paras arvo oli $C = 1$, ja ristiinvalidoinnin ROC-AUC oli 0,989.

3.4 Random Forest

Random Forest -mallissa käytettiin samoja 15 muuttujaa kuin pienemmässä logistisessa regressiossa. Mallissa käytettiin 200 päätöspuuta. Lisäksi vertailtiin kahta puiden maksimisyvyyttä ja kahta lehden vähimmäiskokoa.

Paras malli käytti rajoittamatonta puun syvyyttä ja lehden vähimmäiskokoa 1. Ristiinvalidoinnin ROC-AUC oli 0,989.

3.5 Päätöskynnykset ja arviointi

Luokittelussa ei käytetty automaattisesti päätöskynnystä 0,5. Jokaiselle mallille valittiin erillinen kynnys opetusdatan perusteella maksimoimalla Youdenin J-arvo:

$$J = \text{sensitiivisyys} + \text{spesifisyys} - 1.$$

Valitut kynnykset olivat 0,384 kaikilla muuttujilla tehdyille logistiselle regressiolle, 0,433 pienemmälle logistiselle regressiolle ja 0,465 Random Forestille. Kynnykset valittiin ilman testidatan käyttöä.

Lopullinen arviointi tehtiin tämän jälkeen kerran erillisellä testidatalla. Päämittarit olivat sensitiivisyys, spesifisyys ja ROC-AUC. Sensitiivisyys kuvaa tässä sitä, kuinka hyvin malli tunnistaa pahanlaatuiset kasvaimet.


4. Tulokset

Malli	Muuttujia	Sensitiivisyys s	Spesifisyys s	ROC-AUC	Accuracy
Logistinen regressio, kaikki	30	0,981	1,000	0,998	0,993
Logistinen regressio, valitut	15	0,943	0,989	0,998	0,972
Random Forest, valitut	15	0,925	1,000	0,997	0,972

Kaikki kolme mallia erottelivat hyvän- ja pahanlaatuiset kasvaimet hyvin. Paras testitulos saatiin logistisella regressiolla, jossa käytettiin kaikkia 30 muuttujaa. Sen ROC-AUC oli 0,998, sensitiivisyys 0,981 ja spesifisyys 1,000.

Muuttujamäärän vähentäminen 30:stä 15:een ei käytännössä muuttanut ROC-AUC-arvoa. Pienemmän logistisen mallin ROC-AUC oli myös pyöristettynä 0,998. Sensitiivisyys kuitenkin laski 0,981:stä 0,943:een ja spesifisyys 1,000:sta 0,989:ään.

Random Forest ei parantanut tulosta verrattuna pienempään logistiseen regressioon. Random Forestin ROC-AUC oli 0,997 ja sensitiivisyys 0,925. Spesifisyys oli 1,000. Molempien 15 muuttujan mallien accuracy oli 0,972.



Kuva 1. Kolmen mallin ROC-käyrät testiaineistossa. Käyrät olivat hyvin lähellä toisiaan, mikä vastaa mallien lähes samoja ROC-AUC-arvoja.

5. Pohdinta

Tulosten perusteella rintakasvaimen maligniteettia voidaan ennustaa hyvin solutumien morfologisten ominaisuuksien perusteella tässä aineistossa. Kaikkien kolmen mallin ROC-AUC oli vähintään 0,997.

L1-menetelmä vähensi muuttujamäärän puoleen ilman käytännössä havaittavaa muutosta ROC-AUC-arvossa. Tämä vastaa tutkimuskysymykseen siitä, voidaanko kasvaimet erottaa pienemmällä muuttujajoukolla: tässä aineistossa 15 muuttujaa riitti lähes samaan erottelukykyyn kuin kaikki 30 muuttujaa. Valitulla päätöskynnyksellä pienemmän mallin sensitiivisyys kuitenkin laski hieman.

Random Forest ei tuonut selvää hyötyä logistiseen regressioon verrattuna. Pienempi logistinen regressio sai hieman korkeamman ROC-AUC:n ja sensitiivisyyden, kun taas Random Forest sai hieman paremman spesifisyyden. Koska logistinen regressio on myös yksinkertaisempi ja sen tuloksia on helpompi tulkita, valitsisin näistä kahdesta 15 muuttujan logistisen regressioon.

Kaikilla 30 muuttujalla tehty logistinen regressio sai parhaat testitulokset. Eroja pitää kuitenkin tulkita varovasti. Testiaineisto sisälsi vain 143 näytettä ja 53 pahanlaatuista tapausta. Muutaman

väärän luokituksen ero voi siksi muuttaa sensitiivisyyttä selvästi. Näiden tulosten perusteella ei voida päätellä, että 30 muuttujan malli olisi yleisesti parempi uusissa aineistoissa.

Random Forestin hyperparametrien haku oli myös melko rajattu. Laajempi parametrien optimointi voisi muuttaa sen suorituskkyä, mutta tämän projektin tavoitteena oli vertailla menetelmiä yksinkertaisella ja ymmärrettävällä tavalla.

6. Generatiivisen tekoälyn käyttö

Hyödynsin ChatGPT:tä aineiston etsimisessä, projektisuunnitelman jäsentelyssä sekä raportin oikeinkirjoituksen tarkistamisessa ja kielellisessä viimeistelyssä. Toteutan analyysikoodin itsenäisesti ja teen tulosten lopulliset tulkinnat itse.

7. Koodit

Aineiston alustavassa analyysissä käyttämäni Jupyter Notebook on saatavilla julkisessa GitHub-repositoriossa:

<https://github.com/bumerrang2808/Machine-learning-project>

Lähteet

1. Wolberg, W. H., Street, W. N. & Mangasarian, O. L. *Breast Cancer Wisconsin (Diagnostic)*. UCI Machine Learning Repository.